

Visual SLAM における 鏡面の三次元再構成手法

24RMD16 河合 悠貴

東京電機大学大学院理工学研究科
情報学専攻修士課程
修士論文

東京電機大学
令和7年度

概要

屋内環境で自律移動ロボットが安全に活動するためには、Visual SLAM による環境地図構築が不可欠である。しかし、鏡などの反射物体が存在する環境では、SLAM が鏡像を実空間と誤認識し、地図の破綻や衝突を引き起こす。既存の測距センサは鏡面の直接計測が困難であり、単純な領域除外では地図上に不可視領域が生じてしまう。

本研究では、単眼カメラ画像のみから鏡面の三次元位置および姿勢を推定し、環境地図に統合するシステムを提案する。まず、U-Net によるセマンティックセグメンテーションで鏡面領域を抽出し、IoU 0.919 の高い精度と約 24.7 FPS のリアルタイム推論を達成した。次に、鏡面に映るマーカー (AprilTag) の幾何学的拘束を利用して鏡面の方程式を推定し、約 1.1 m 以内で誤差数 mm の高精度な推定を実現した。データセット全体においても、投影点群が実際の鏡面領域を IoU 0.943 で適切に覆うことが確認された。

これらの三次元再構成結果を RTAB-Map の地図に統合し、ROS 2 のナビゲーション (Nav2) のコストマップ上に障害物として反映させることで実用性を実証した。さらに、動的ノイズへの対応やループクロージングへの介入の必要性についても考察する。

Abstract

For autonomous mobile robots to operate safely indoors, environmental mapping using Visual SLAM is essential. However, in environments with reflective objects like mirrors, SLAM misrecognizes mirrored images as real space, leading to map corruption and collisions. Conventional depth sensors struggle to measure mirrors directly, and merely excluding these regions creates unnavigable invisible areas.

This study proposes a system to estimate the 3D position and orientation of mirrors solely from monocular camera images, integrating this information into the environmental map. First, mirror regions are extracted using U-Net-based semantic segmentation, achieving a high accuracy with an IoU of 0.919 and real-time inference at approximately 24.7 FPS. Next, the mirror's equation is estimated using the geometric constraints of a marker (AprilTag) reflected in the mirror. Experimental evaluations confirmed high-precision estimation with an error of a few millimeters within a 1.1 m range. Across the entire dataset, the 3D projected point cloud appropriately covered the actual mirror regions with an IoU of 0.943.

The practicality of this system was demonstrated by integrating the reconstruction results into RTAB-Map and reflecting them as physical obstacles on the ROS 2 navigation (Nav2) costmap. Finally, the necessity of addressing dynamic noise and intervening in the loop-closure process is discussed.

目 次

第 1 章 序論	1
1.1 研究背景.....	1
1.2 先行研究に基づく課題の整理	2
1.3 課題.....	2
1.4 研究目的.....	2
1.5 論文の構成	2
第 2 章 関連研究	3
2.1 Visual SLAM の概要と代表的手法	3
2.2 鏡面・透明物体が SLAM に与える影響	3
2.3 鏡および透明物体への既存の対処手法.....	3
2.3.1 センサ特性を利用した手法	3
2.3.2 センサ融合による手法	3
2.3.3 画像認識・機械学習による手法.....	4
2.3.4 鏡面の幾何学的利用と再構成手法	4
2.4 鏡面の三次元再構成とロボットナビゲーションへの応用	4
第 3 章 提案手法	6
3.1 システム概要	6
3.2 セマンティックセグメンテーションによる鏡面認識	8
3.3 鏡像マーカーを用いた鏡面位置推定	8
3.4 SLAM マップ情報への反映とナビゲーション	10
第 4 章 実装	11
4.1 移動ロボット	11
4.1.1 システム概要.....	11
4.1.2 実装環境.....	12
4.1.3 ロボットの製作	13
4.1.4 カメラ・マーカー間の距離計測	14
4.1.5 移動制御システムの実装.....	16
4.2 セグメンテーションモデルの構築.....	17
4.2.1 モデル実装に関する概要.....	17
4.2.2 実装環境.....	18
4.2.3 データセットの構築.....	19
4.2.3.1 事前学習用公開データセット	19
4.2.3.2 ファインチューニング用独自データセット	19

4.2.4 モデルの事前学習	21
4.2.4.1 前処理およびデータ拡張	21
4.2.4.2 クラス不均衡への対策と損失関数の定式化	21
4.2.4.3 ハイパーパラメータ探索と学習手順	21
4.2.5 モデルのファインチューニング	22
4.2.5.1 データ拡張およびクラス不均衡への適応	22
4.2.5.2 転移学習とハイパーパラメータの再探索	23
4.2.5.3 学習結果と最終モデルの保存	23
4.3 鏡面再構成システムの実装	24
4.3.1 システム概要	24
4.3.2 実装環境	25
4.3.3 モデルのデプロイ	25
4.3.4 マーカー検出	25
4.3.5 鏡面位置の特定	25
4.3.6 データのクラスタリング	26
4.3.7 SLAM マップへの投影	26
第 5 章 評価	27
5.1 評価概要	27
5.2 セマンティックセグメンテーションによる鏡面検出	28
5.2.1 モデルの定量評価	28
5.2.2 実環境における検出結果	28
5.3 鏡面位置推定精度の定量評価	32
5.3.1 実験条件と真値の定義	32
5.3.2 距離および法線ベクトルの推定精度	32
5.3.3 再構成点群の投影精度の定量評価	35
5.4 Visual SLAM への統合とナビゲーション応用の評価	38
第 6 章 考察	41
6.1 システムの有効測定範囲と走行安全性	41
6.2 キャリブレーション誤差の影響と斜め方向からの観測における課題	41
6.3 静止状態と走行状態によるセグメンテーション精度の違い	41
6.4 複数地点での鏡面観測におけるループクロージングの破綻	42
第 7 章 結論	43
謝辞	44
参考文献	45

第1章 序論

1.1 研究背景

近年、少子高齢化による労働力不足を背景として、物流倉庫、商業施設、オフィスビル、家庭といった屋内環境におけるサービスロボットの導入が急速に進んでいる。これらの環境でロボットが人間と共存し、搬送や清掃などのタスクを安全かつ効率的に遂行するためには、ロボット自身が周囲の環境を正確に認識し、自己の位置を把握する能力が不可欠である。特に、カメラや LiDAR (Light Detection and Ranging) などのセンサを用いて環境の形状や外観を計算機上で再現する三次元再構成 (3D Reconstruction) 技術[1]は、ロボットの自律走行における基盤技術として位置づけられている。ロボットは構築された三次元地図 (マップ) に基づき、自己位置推定 (Localization)、障害物回避、経路計画 (Path Planning) を行うため、この地図の精度はロボットの安全性とタスク達成率に直結する重要な要素である。

環境地図の構築と自己位置推定を同時に行う技術である SLAM (Simultaneous Localization and Mapping) の中でも、カメラ画像を用いる Visual SLAM は、安価なハードウェア構成で豊富なテクスチャ情報や色情報を取得できる利点があり、広く研究・実用化が進められている。カメラを用いた三次元計測の多くは、物体表面での光の反射特性として、どの方向から見ても輝度が一定である「ランバート反射 (拡散反射)」を前提としている[2]。また、ToF (Time of Flight) 方式の深度カメラやステレオカメラなどの能動的・受動的センサにおいても、物体表面での光の散乱や視差情報を利用して距離を算出する。一般的なオフィスや住環境のデータセットでは、壁、床、家具などの多くがこの仮定を満たすため、Visual SLAM は良好に動作する。しかし、現実の屋内環境には、鏡、ガラス、研磨された金属面など、高い鏡面反射性を持つ物体が数多く存在し、これらの物体は Visual SLAM の前提条件から外れるため、依然として技術的なボトルネックとなっている。

鏡面反射を伴う物体、とりわけ「鏡」の存在は、Visual SLAM による環境認識において深刻なエラーを引き起こす。鏡は周囲の環境光を正反射し、鏡面の奥に「虚像」として偽の三次元空間を映し出す性質を持つ。従来の Visual SLAM アルゴリズムや深度センサは、この虚像を実在する空間として誤って知覚してしまう。具体的には、特徴点マッチングにおいて鏡の中の虚像の特徴点が追跡され、実空間の幾何学的整合性が破綻する、あるいは深度センサが鏡面までの距離ではなく、鏡に映り込んだ物体までの距離を計測してしまうといった現象が発生する。この結果、生成される三次元地図には、実際には存在しない部屋や廊下が「鏡の向こう側」に誤って再構成される。このような誤った地図情報は、自己位置推定のカルマンフィルタや最適化計算における外れ値となり、推定精度の著しい低下を招く。さらに、ナビゲーションにおいては、ロボットが鏡を「通過可能な空間」と誤認識し、衝突事故を引き起こすリスクが増大するため、安全上の重大な懸念事項となっている。

これまでも、超音波センサの併用による鏡検出などが試みられてきた。しかし、これら

の手法はセンサ構成の複雑化といったハードウェアレベルの制約を含むことが多い。

したがって、視覚情報のみを用いて、環境内のどこに鏡が存在するかを正確に識別し、それを地図構築プロセスにおいて適切に扱う技術が求められている。ロボットにおいても単なる幾何学的な距離計測だけでなく、画像に含まれるコンテキストから「そこにあるのが鏡である」と判断する、意味論的（セマンティック）な環境理解の導入と実機による検証が必要不可欠となっている。

1.2 先行研究に基づく課題の整理

鏡面反射物体が Visual SLAM に与える影響については、これまでに複数の研究が報告されている。Herbert ら[3]は、鏡面を含む環境において ORB-SLAM をはじめとする代表的な Visual SLAM 手法を評価し、鏡像が実在構造として誤って地図化されることで地図構築が破綻する事例を示している。結果として、鏡面を含む環境では、既存の Visual SLAM 手法が鏡像を実構造として誤認識し、地図構築が破綻する問題が依然として解決されていないことが明らかとなっている。

この問題に対し、Aydin ら[4]は物体検出モデルを用いて鏡面を識別し、ORB-SLAM3 における特徴点処理へ反映することで、鏡面による誤対応を抑制する手法を提案している。このようなアプローチにより自己位置推定精度の改善は報告されているが、鏡面は誤差要因として扱われ、地図構造として明示的に再構成されてはいない。したがって、鏡面を検出して SLAM の誤対応を抑制する手法は存在するものの、鏡面を三次元構造として地図に統合し、ナビゲーションに利用するまでには至っていない。

一方で、Whelan ら[5]は、鏡面に映り込む視覚マーカーを利用して鏡面の幾何学的構造を推定する手法を報告している。この手法は、鏡面を単に除外するのではなく、再構成対象として扱う点で有効である。しかし、鏡面の幾何学的再構成手法は存在するものの、自律移動ロボットのナビゲーションに統合した実機検証は行われていない。

1.3 課題

以上の先行研究から、単眼視覚のみを用いて鏡面を三次元的に再構成し、実機ロボットのナビゲーションに統合した検証が未だ十分に行われていない点が課題である。

1.4 研究目的

本研究の目的は、鏡面を環境内の物理的障害物として三次元地図に統合し、鏡面環境下においても安全かつ安定した自律移動を実現することである。

1.5 論文の構成

本論文は、第 1 章で研究背景、課題および研究目的を述べる。第 2 章では、Visual SLAM および鏡面反射物体に関する既存研究を整理する。第 3 章では、本研究で提案する鏡面三次元再構成手法の概要を示す。第 4 章では提案手法の実装について述べ、第 5 章で評価実験とその結果を示す。第 6 章では得られた結果に対する考察を行い、第 7 章で結論と今後の課題を述べる。

第2章 関連研究

2.1 Visual SLAM の概要と代表的手法

自己位置推定と地図構築を同時に行う SLAM (Simultaneous Localization and Mapping) 技術は、自律移動ロボットの実現に不可欠である[6]。中でもカメラを用いる手法は Visual SLAM と呼ばれ、代表例として ORB-SLAM[7]が挙げられる。ORB-SLAM は単眼カメラによる特徴点ベースの SLAM 手法であり、高い精度と汎用性が報告されている。また、RTAB-Map[8]は LiDAR やステレオカメラなど複数センサに対応したグラフベースの SLAM フレームワークであり、大規模かつ長期の地図生成にも耐えるオープンソースライブラリとして提供されている。

2.2 鏡面・透明物体が SLAM に与える影響

しかしながら、従来の Visual SLAM アルゴリズムの多くは環境中の鏡やガラスなどの鏡面・透明物体の存在に対して脆弱である。例えば、Herbert ら[3]は鏡面環境下で ORB-SLAM を含む主要な Visual SLAM 手法を評価し、鏡に映った物体の虚像を実在の特徴として誤認した結果、地図が破綻するケースを報告している。このような誤認識は、鏡やガラスがセンサに対して本来の位置・形状とは異なる情報（反射像や透過による欠損）を与えるために生じる。鏡では表面に映り込んだ物体が実在物と区別できず、SLAM はそれらを誤って環境中の特徴として取り込んでしまう。また、LiDAR においても鏡面は計測を混乱させ、全反射による虚像の検出や無反射によるデータ欠落を引き起こすことが指摘されている[9]。

2.3 鏡および透明物体への既存の対処手法

鏡面や透明物体による問題を解決するため、様々なアプローチが提案されている。Mo ら[10]の調査によれば、これらの手法は大きく (i) センサの物理特性を活用する手法、(ii) 複数種類のセンサ情報を組み合わせる手法、(iii) カメラ画像に基づく機械学習手法に分類できる。以下、それぞれの代表的な例について述べる。

2.3.1 センサ特性を利用した手法

センサ固有の物理特性を活用した鏡検出手法も研究されている。谷口ら[11]は深度カメラで取得した点群データから鏡の枠に相当する特徴を抽出し、その領域で鏡像点群が観測されるかを検証することで鏡面を検出している。一方、須藤ら[12]は鏡やガラスの半透明性に着目し、レーザーポインタを照射して単眼カメラでその反射光を観測することでガラス面を特定する能動的な手法を提案している。また、Käshammer と Nüchter[13]は既知の寸法を持つ枠付き鏡をマーカーとして利用し、地上型レーザスキャンで取得した点群中からその鏡を識別して、反射による誤った点群を除去する手法を報告している。

2.3.2 センサ融合による手法

複数の異種センサを組み合わせることで鏡やガラスを検出・対応するアプローチも提案されている。例えば、山口ら[14]は偏光カメラとレーザレンジファインダ (LRF) を併用し、偏光画像からガラス面の存在方向を推定して不足する点群を補完することで、SLAM 環境

下でのガラス面検出とマップ修正を可能にしている。また、Wei ら[15]は超音波センサと LiDAR の情報を融合し、超音波でガラスからの反射を捉えることでロボットの走行環境におけるガラス障害を検知する手法を提案している。青木ら[16]は超音波センサと LED 光源の反射を利用し、Visual SLAM におけるガラス面と鏡面のマッピング手法を提案し、移動ロボットによる実機検証を実施した。

2.3.3 画像認識・機械学習による手法

カメラ画像を用いたアプローチとして、画像解析や機械学習による鏡・透明物体の検出も盛んに研究されている。Klank ら[17]は移動ロボットに搭載した ToF カメラの強度画像からガラス面を検出し、透明物体の三次元形状を再構成する手法を示している。近年では、大規模なデータセットを用いた深層学習により検出精度の向上が図られている。Mei ら[18]は実環境で撮影した多数のガラス面画像を収集し、“Don’t Hit Me!”と題するデータセットを公開するとともに、単眼画像からガラス領域を認識する深層学習モデル (GDNet) を提案している。また、Zhao ら[19]は RGB-D カメラで取得した深度情報の不整合に基づいて室内環境のガラス面を検出し、その点群データを SLAM の入力から除去することで地図歪みの低減を図っている。さらに、Aydin ら[4]は物体検出モデル YOLOv8 を応用して室内シーン中の鏡を高精度に識別し、その結果を ORB-SLAM3 の地図更新処理で考慮することで軌跡推定誤差の低減に成功している。

2.3.4 鏡面の幾何学的利用と再構成手法

前節までの多くの手法は、鏡やガラスを検出して SLAM の処理から除外することに焦点を当てていた。一方で、反射面そのものを地図に組み込んだり、鏡像から得られる情報を積極的に利用したりするアプローチも存在する。古典的な研究例として、Rodrigues ら[20]は平面鏡に映った物体像を仮想カメラからの観測として利用し、カメラの姿勢を推定する幾何学的手法を提案している。Whelan ら[5]は環境内に配置した AR マーカーを用いて鏡やガラスの平面を認識・位置推定し、地図中にそれらを明示的に再現する SLAM システムを実現している。具体的には、AprilTag[21]と呼ばれるマーカーの鏡像を検出することで鏡面の位置・姿勢を推定し、それをシーン再構成に組み込むことによって、鏡やガラス面を含む環境を正確にモデリングしている。また、Chen ら[22]は ORB-SLAM2 に深層学習ベースのガラス検出モジュール (CGSDNet-Depth) を組み込み、ガラス面による特徴点マッチ誤対応を低減して高密度な環境復元を可能とする手法を報告している。さらに、Tan ら[23]は鏡面領域の深度推定精度を改善するため大規模データセット Mirror3D を公開し、鏡に対する深度補正モデルを学習することで鏡面上でも一貫した 3 次元復元が可能であることを示している。加えて、Arnolte ら[24]は Mirror3DNet と最先端の単眼深度推定モデルを組み合わせ、単一画像から鏡を検出してシーンの 3 次元復元に反映させる試みを報告している。

2.4 鏡面の三次元再構成とロボットナビゲーションへの応用

既存の手法は、おおまかに鏡・ガラスを検出して SLAM から排除する手法と、限定的な条件下で鏡面を地図に組み込む手法に大別できる。それぞれセンサの工夫や機械学習の活

用によって一定の成果が報告されているが，一般的な環境下で鏡や透明物体に対処する統一的な解決策は未だ確立されておらず，手法ごとに特定の条件やセンサに依存した対応となっているのが現状である．また，研究動向に関して，透明物体認識の包括的レビュー[25]や，鏡・ガラス・カモフラージュ物体など紛らわしい物体検出手法のサーベイ[26]も近年報告されており，鏡面・透明物体への対処がロボットの知覚において重要な課題であることが指摘されている．

既存研究の多くは鏡面を誤差要因として扱い，SLAM の処理から除外する方針を採っている．これに対し，本研究は鏡面を環境中の明示的な構造物として再構成し，実機ロボットのナビゲーションに直接利用する点で異なる立場を取る．

第3章 提案手法

本章では、既存研究が鏡面を誤差要因として扱うのに対し、鏡面を構造物として再構成し地図に統合するという立場に基づき、単眼カメラ画像を用いた提案手法について述べる。

3.1 システム概要

本研究で鏡面を検出し、その形状を再構成する手法を実現するシステムを図 1 に示す。




図 1 システム概要図

通常の Visual SLAM はカメラの映像データをはじめとしたセンサデータを入力とし、被写体である周辺環境とカメラ自身の相対的な位置関係を三次元で可視化する処理をリアルタイムで実行する。提案手法は Visual SLAM が必要とする RGB 映像データを利用し、鏡面の検出と三次元再構成を独自のシステムとして実行することで、構築される三次元地図データの鏡面をリアルタイムで補完する。これにより Visual SLAM で取得するセンサデータのみを用いて三次元地図上における正確な鏡面の反映とそれを利用した移動ロボットの正確なナビゲーションの安全性向上に寄与する。

このシステムは Visual SLAM とともに実行されることを前提とし、多くの Visual SLAM のアルゴリズムと独立して動作するシステムとすることで、さまざまなアルゴリズムへの適用を想定している。そのため多くの Visual SLAM で使用される RGB 画像のみを入力と

し、鏡面に関わる情報のみを出力するシステムを構築することで多様な SLAM システムへの適用を目指す。

本研究では鏡面領域を再構成するために RGB の映像データに対して2つの処理を並行して実施する。これらの処理は最終的に鏡面領域と鏡面の三次元位置をもつ情報として Visual SLAM の三次元地図データに統合される。

図 1 に示す提案するシステムの処理フローのうち、上部の処理は画像中から鏡面の領域を検出し、鏡面領域を推定する処理である。下部の処理は撮影しているカメラと鏡面までの相対位置を計算し、三次元地図データ上の鏡面位置を特定する処理である。この2つの処理から得られる鏡面領域・鏡面位置の推定結果から鏡面の再構成を実行し、Visual SLAM の三次元地図データに鏡面の情報を補完する。

本研究で提案するシステムは Visual SLAM とともに移動ロボット上のカメラの情報を利用し、環境理解と自律ナビゲーションを実行する機能である。そのため本研究のシステムはロボットに搭載された Visual SLAM を実行するカメラデバイスの映像データを元にシステムを実行する。移動ロボットが鏡面を検出する様子を示すイメージを図 2 に示す。




図 2 鏡面を観測するロボットの平面図

移動ロボットの進行方向を向くようにカメラデバイスを設置し、Visual SLAM を実行する。その際、移動ロボットが鏡面と正対した場合、鏡面との位置関係は図 2 の平面図のような状態になることが予想される。この場合、鏡面の右手にある移動ロボットのカメラは鏡面に映り込む鏡像（鏡面の左手）としてロボット自身を観測する。

ロボット自身が鏡像として映り込む鏡面反射を利用し、鏡面とロボットとの相対的な位

置関係を求めるため、本研究は視覚基準マーカー（以下、マーカー）を利用する。このマーカーはカメラで撮影されると、カメラとの距離や回転などを検出することができる。ロボット本体にこのマーカーを貼り、鏡像として映り込むロボットからこのマーカーを検出できるようにする。

鏡面に映り込むマーカーは図 2 の赤矢印で表される幾何的な拘束が発生する。実像と鏡像は鏡面に対して対称な位置関係となる。したがって、実像のマーカーと鏡像のマーカーを結ぶ線の中点が鏡面の位置を示す代表点となる。

この幾何的な拘束を利用し、鏡面を推定するために必要となる情報は図 2 の緑矢印で表されるカメラから実像・鏡像マーカーまでのそれぞれの距離と回転の情報である。本研究では鏡面に映り込むマーカーをカメラで検出し、鏡像マーカーの位置を検出する他、実像マーカーはカメラとの位置関係を事前に計測し、固定パラメータとして扱う。これにより、鏡像マーカーの観測が始まると鏡面の代表点の位置を計測することができるようになり、カメラによる鏡面の位置推定を実現する。

3.2 セマンティックセグメンテーションによる鏡面認識

図 1 に示す提案する手法では鏡面領域の検出と投影を実行するが、本研究ではこの処理にセマンティックセグメンテーションを用いる。セマンティックセグメンテーションはディープラーニング技術を用いた画像認識タスクであり、画像中からピクセルごとに物体のクラスラベルを特定することができる。本研究では移動ロボットに取り付けたカメラからの RGB 映像データをセマンティックセグメンテーションのモデルに入力し、画像中に出現する鏡面の領域を 2 値マスク画像として後段の後処理に渡す。

次に、セマンティックセグメンテーションで得られたマスク画像に対し、平滑化を行う。得られたマスク画像にはノイズとして鏡面マスクに細かな欠損が含まれていることがあるため、マスク画像の平滑化を実施する。

その後、複数のマスク画像のフレームの情報から確率的に鏡面が含まれている場所を占有グリッドとして更新し、三次元地図データに投影する鏡面領域とする。

3.3 鏡像マーカーを用いた鏡面位置推定

本手法では、カメラ座標系における鏡面のパラメータ（法線ベクトル $\mathbf{n}$ および原点から鏡面までの距離 d ）を推定するために、鏡面反射の幾何学的性質を利用する。

カメラ座標系 Σ_c において、実像マーカー（ロボットに固定）の姿勢を表す同次変換行列を T_{real} 、鏡面に映り込んだ虚像マーカーの姿勢を表す同次変換行列を T_{virt} とする。ここで、変換行列 T は回転行列 $R \in SO(3)$ と並進ベクトル $\mathbf{t} \in \mathbb{R}^3$ を用いて以下のように定義される。

$$T = \begin{bmatrix} R & \mathbf{t} \\ \mathbf{0}^T & 1 \end{bmatrix} \quad (3.1)$$

実像マーカー T_{real} はロボットの機構設計値およびキャリブレーションにより既知であり、虚像マーカー T_{virt} はカメラ画像上の AprilTag 検出処理により計測される。鏡面反射

による変換行列を S とすると、実像と虚像の間には以下の関係が成り立つ.

$$T_{virt} = S \cdot T_{real} \quad (3.2)$$

したがって、反射変換行列 S は観測された T_{virt} と既知の T_{real} から次式で算出できる.

$$S = T_{virt} \cdot T_{real}^{-1} \quad (3.3)$$

ここで、鏡面が平面であり、その単位法線ベクトルを $\mathbf{n} = [n_x, n_y, n_z]^T$ ($\|\mathbf{n}\| = 1$), カメラ原点から鏡面までの符号付き距離を d とするとき、鏡面による反射変換 S は Householder 変換を用いて以下のように記述される.

$$S = \begin{bmatrix} H & 2dn \\ \mathbf{0}^T & 1 \end{bmatrix} \quad (3.4)$$

ここで、 H は Householder 行列であり、法線ベクトル $\mathbf{n}$ を用いて次式で表される.

$$H = I - 2\mathbf{n}\mathbf{n}^T \quad (3.5)$$

ここで I は 3×3 の単位行列である. 式(3.4)より、算出された S の回転成分 R_S は H に、並進成分 $\mathbf{t}_S$ は $2d\mathbf{n}$ に対応する. これらを用いて、鏡面パラメータ n, d を以下の手順で復元する.

まず、回転成分 $R_S (= H)$ と式(3.5)の関係より、行列 M を定義する.

$$M = \frac{1}{2}(I - R_S) = \mathbf{n}\mathbf{n}^T \quad (3.6)$$

この行列 M はランク 1 の対称行列となる. したがって、 $\mathbf{n}$ は行列 M を特異値分解(SVD)した際の最大特異値に対応する特異ベクトル (または最大固有値に対応する固有ベクトル) として求められる.

次に、並進成分 $\mathbf{t}_S$ は式(3.4)より $\mathbf{t}_S = 2d\mathbf{n}$ であるため、距離 d は次式により求められる.

$$d = \frac{1}{2}\mathbf{n}^T\mathbf{t}_S \quad (3.7)$$

なお、法線ベクトル $\mathbf{n}$ の向きには符号の不定性があるため、カメラが鏡面の正の領域 (あるいは負の領域) に存在するという物理的制約に基づき、符号を一意に決定する. 本実装では、カメラから見て鏡面が前方にある (平面の方程式 $\mathbf{n}^T\mathbf{x} + d = 0$ において距離が正しく定義される) ように補正を行っている.

以上の処理により、単眼カメラの 1 フレームの観測から鏡面の三次元位置姿勢を一意に特定することが可能となる.

しかし、単一フレームから得られる鏡面パラメータには、カメラの姿勢推定誤差やマーカ検出のノイズが含まれるため、時系列的な安定性に欠ける場合がある. また、環境内に複数の鏡が存在する場合、それらを個別の鏡として識別する必要がある. そこで本手法では、時系列的に得られる多数の鏡面パラメータ推定値に対し、Whelan ら[5]が提案した DP-Plane クラスタリングを適用することで、鏡面の枚数とそれぞれの正確な位置姿勢をロバストに推定する. 一般的な K-means 法などのクラスタリング手法は事前にクラスタ数 (鏡の

枚数)を指定する必要があるが、未知環境を探索するロボットにとって鏡の枚数は未知数である。DP-Plane 法は、新たな観測データが既存のクラスタ中心から一定の閾値 λ 以上離れている場合に、動的に新たなクラスタを生成する仕組みを持つノンパラメトリックな手法である。

具体的には、推定された各平面パラメータについて、以下の式で定義される対称点平面距離 (Symmetric Point-to-Plane Distance) を用いて類似度を評価する。

$$\text{dist}([\mathbf{p}_a, \mathbf{n}_a], [\mathbf{p}_b, \mathbf{n}_b]) = \frac{1}{2}(|(\mathbf{p}_a - \mathbf{p}_b) \cdot \mathbf{n}_b| + |(\mathbf{p}_b - \mathbf{p}_a) \cdot \mathbf{n}_a|) \quad (3.8)$$

ここで、 $\mathbf{p}$ は平面上の代表点 (マーカー中心の投影点など)、 $\mathbf{n}$ は法線ベクトルである。この距離が閾値 λ 以内の場合、その観測は既存の鏡面クラスタに統合され、クラスタのパラメータ (重心および平均法線) が更新される。これにより、ノイズを含む観測値から、環境内に実在する各鏡面のパラメータを一意かつ高精度に決定する。

3.4 SLAM マップ情報への反映とナビゲーション

3.3 節の手法により、環境内に存在する鏡面の数学的なパラメータ (法線ベクトル $\mathbf{n}$ および距離 d) が一意に決定される。しかし、ナビゲーション用地図として利用するためには、無限に広がる平面ではなく、鏡の実体が存在する領域のみを有限な「壁」として表現する必要がある。そこで本節では、3.2 節で得られた鏡面領域のセグメンテーション結果と統合し、三次元空間上に鏡面ポリゴンを生成する手法について述べる。

まず、セグメンテーションモデルによって抽出された鏡面領域のマスク画像から、鏡の輪郭を構成する画素群を抽出する。次に、カメラの内部パラメータ $\mathbf{K}$ を用いて、各輪郭画素に対応する視線ベクトル (レイ) を生成し、推定された鏡面平面との交点を算出する。画像上の画素座標 $\mathbf{u} = [u, v]^T$ に対応する正規化カメラ座標系の視線ベクトルを $\mathbf{r} = \mathbf{K}^{-1}[\mathbf{u}, 1]^T$ とすると、平面 $\mathbf{n}^T \mathbf{x} + d = 0$ との交点 $\mathbf{P}$ は次式で求められる。

$$\mathbf{P} = -\frac{d}{\mathbf{n}^T \mathbf{r}} \mathbf{r} \quad (3.9)$$

この処理を輪郭上の全ての点に対して適用することで、三次元空間上における鏡面の境界線 (ポリゴン) が得られる。

最後に、生成された鏡面ポリゴンを Visual SLAM システム (本研究では RTAB-Map を想定) の三次元地図データに統合する。通常、Visual SLAM は鏡像を奥行きのある空間 (自由領域) として認識してしまうが、本手法では生成したポリゴンを「通行不可領域 (障害物)」として地図上に配置する。これにより、ロボットの経路計画 (Path Planning) アルゴリズムは、鏡の奥に広がる虚像空間への進入経路を探索候補から除外し、鏡面を物理的な壁として認識して回避する経路を生成することが可能となる。

第4章 実装

4.1 移動ロボット

4.1.1 システム概要

本研究では提案するシステムを実行するための移動ロボットの製作を行った．ハードウェアのシステムの構成を図 3 に示す．




図 3 移動ロボットのハードウェア構成図

本研究で製作した移動ロボットは、TurtleBot3 キャリアロボット[27]の設計を参考に構築した．この設計を基に機体構造ならびに制御インターフェースを改めた．

Visual SLAM 並びに本研究で提案するシステムは RealSense D455[28] (以下, RealSense) で観測されたデータから実行する．D455 はステレオ方式による深度推定機能および慣性計測ユニット (IMU) を備えた RGB-D カメラであり、本研究における三次元計測に利用した．このカメラは移動ロボットに実装されるが、USB ケーブルを介した接続先は移動ロボットに搭載したモバイル PC ではなく、システムを実行する外部の PC へ接続される．この PC で Visual SLAM を含むシステムが実行され、ロボットの周辺環境のマッピングが実行される．

RealSense の付近には鏡面に映り込ませることで観測を行うマーカーとして AprilTag を貼り付ける．紙に印刷した 12cm 四方のマーカーを LED パネルライトに貼り付けた状態でロボットに搭載した．LED パネルライトはマーカー自体を発光させることで鏡像マーカーの検出を促す目的で採用したものの、自己発光によるコントラスト向上の効果よりも、白飛びによる検出精度の低下が顕著であったため、本実験では発光機能を使用せずに運用した．

RealSense と AprilTag を搭載する移動プラットフォームはコントローラーによる信号を

入力とし、2つのサーボモーターにそれぞれ接続された車輪の回転速度・回転方向を制御することで移動ロボットを走行させる。なお、移動プラットフォーム全体の制御は移動ロボットに搭載したモバイルPCによって実行される。

また、モバイルPCはシステム実行PCとWi-Fiで接続されており、Visual SLAMのマップを用いた自律移動を実行するときは、コントローラーからの入力ではなくシステム実行PCから指令が送られる設計とした。

4.1.2 実装環境

移動ロボットの開発および動作検証は表1の環境で行った。

表 1 移動ロボットの实装環境

使用機器・ソフトウェア	型番・バージョン
モバイルPC	Dell Inspiron 14 5440
OS	Ubuntu 22.04
CPU	Intel Core i3-1305U
メモリ	8GB
Visual Studio Code	1.105.1
Autodesk Fusion	2602.1.25
DYNAMIXEL SDK	3.8.4
Python3	3.10.12
Apriltag_ros[29]	3.2.2
ROS 2	Humble
PlayStation-JoyInterface-ROS2[30]	1.1.2

4.1.3 ロボットの製作

移動ロボットの製作に使用したハードウェアを表 2 に示す.

表 2 移動ロボットの使用ハードウェア

名称	規格・サイズ	個数
ネジ	M3 8mm	192
ナット	M3	128
六角穴付ボルト	M4 20mm	4
ナット	M4	6
カメラ固定ネジ	1/4 インチ	2
カメラ用ベースプレート	-	1
Intel RealSense D455	-	1
撮影用ライト	-	1
TB3 Waffle Plate-IPL-01	-	32
六角オネジメネジスペーサー	M3 50mm	32
六角オネジメネジスペーサー	M3 30mm	8
六角両メネジスペーサー	M3 20mm	8
ネジ	M2.6 12mm	16
ネジ	M4 18mm	2
丸ワッシャー	M4	6
ボールキャスター	-	1
LiPo バッテリー	11.1V	1
DYNAMIXEL XL430-W250-T (サーボモーター)	-	2
O リング	厚さ 3.1mm 内径 104.4mm	6
丸形両メネジスペーサー	M3 80mm	12
六角両メネジスペーサー	M3 35mm	12
USB シリアル変換インターフェース U2D2	-	1
U2D2 PHB Set	-	1
タミヤ ユニバーサルプレート用スライドアダプター	-	1
面ファスナーストラップ	長さ 200mm	4
バッテリー用耐火バッグ	-	1
SONY DUALSHOCK 4 (コントローラー)	-	1
AprilTag	36h11 120mm 四方	1
USB 延長ケーブル	10m	

この他にも 3D プリンターを用いてサーボモーターに接続するタイヤ[31]とカメラ・マーカを取り付けるアダプターを印刷した.

完成した移動ロボットの様子を図 4 に示す.




図 4 製作した移動ロボット

4.1.4 カメラ-マーカ間の距離計測

図 4 の移動ロボットの RealSense の RGB カメラと AprilTag マーカーの距離を AprilTag の姿勢推定に基づいて算出した. 図 5 は実際の計測の様子である.



図 5 カメラ-マーカ間の距離計測の様子

移動ロボットに搭載されるマーカは鏡面反射した鏡像をカメラから観測するため, 本来のパターンとは左右反転させたものを取り付けている. 計測においてはこのマーカの検出を外部のカメラから実行する必要があるため, 上からサイズの等しい計測用のマーカを貼り付けた. また, 距離計測にあたって壁面へ追加のマーカを, 計測用のカメラとして Luxionis OAK-D S2 (以下, OAK-D) [32]を使用した. マーカを利用した計測のイメージを図 6 に示す.




図 6 計測のイメージ

図 6 の赤矢印が移動ロボットのマーカーと RealSense の距離を示す．これらの位置関係はカメラ内部にあるマーカーの計測始点を含むため，外部からの物理的な計測が困難であった．そこで，二つのカメラと二つのマーカーを利用した手法で距離を測定した．RealSense は壁面のマーカーを観測(緑矢印)し，OAK-D では二つのマーカーを同時に観測する（橙矢印）．これによって，3つの距離情報を合計した場合の視点と終点が RealSense の RGB カメラと移動ロボットのマーカーの中心点となり，赤矢印で示すカメラ・マーカー間の距離計測を実行した．実際に計測された結果を表 3，表 4 に示す．

表 3 距離の計測結果

X [m]	Y [m]	Z [m]
0.017545	-0.080829	-0.021476

表 4 向きの計測結果

Roll [rad]	Pitch [rad]	Yaw [rad]
-0.023080	0.001224	-3.131105

4.1.5 移動制御システムの実装

本研究ではシステムの実装に ROS 2[33]を用いた。ROS 2 はロボット研究・開発に用いるフレームワーク・ミドルウェアのオープンソースソフトウェアである。ROS 2 はロボットのシステムをノードと呼ばれるまとまりごとに単一の機能を実装し、それらの入出力をミドルウェアの通信で接続することで目的の機能を実現する構造となっている。移動ロボットのモバイル PC 上の ROS で動作するシステムの構成図を図 7 に示す。




図 7 移動制御システムの概要図

- コントローラー入力ノード: コントローラー (DUALSHOCK4) のボタンやスティックの入力を検出し、結果を出力する。
- 信号変換ノード: コントローラーの入力を移動ロボットの制御指令に変換し、結果を出力する。
- モーター制御ノード: 入力される制御指令から差動二輪の運動学で角速度を算出し、モーター (タイヤ) を動作させる。

なお、実際にコントローラーを用いて動作させた場合の速度設定を表 5 に示す。速度設定には 2 種類の状態を用意し、環境に合わせて速度を変更できるようにした。

表 5 移動ロボットの速度設定

通常		高速	
直進速度 [m/s]	旋回速度 [rad/s]	直進速度 [m/s]	旋回速度 [rad/s]
0.08	0.3	0.12	0.6

4.2 セグメンテーションモデルの構築

4.2.1 モデル実装に関する概要

本研究では、単眼カメラから取得した RGB 画像から鏡面領域をピクセル単位で高精度に抽出するため、深層学習を用いたセマンティックセグメンテーションモデルを構築する。本節では、採用したネットワークアーキテクチャおよび学習の全体方針について述べる。

1) ネットワークアーキテクチャ

セグメンテーションモデルの基本構造には、エンコーダ・デコーダ構造を持ち、局所的な特徴と大局的な文脈情報を効果的に統合できる U-Net アーキテクチャを採用した。

本モデルは、入力として 3 チャンネルの RGB 画像を受け取り、出力としてピクセルが鏡面領域に属する確率を表す 1 チャンネルの確率マップ (0.0~1.0) を生成する構造とした。また、限られたデータセットでの過学習 (Overfitting) を抑制するため、ネットワーク内部の各層に Dropout 層および Bottleneck Dropout 層を組み込む形とした。

2) 2 段階の学習アプローチ (転移学習)

鏡面は環境によって映り込む物体や照明条件が大きく変化するため、特定の環境のみのデータで学習を行うと、未知の環境やわずかな条件変化に対する汎化性能が低下する恐れがある。そこで本研究では、以下の 2 段階の学習アプローチ (転移学習) を採用した。

最初に実施する学習は事前学習である。大規模な公開データセットを用いてネットワークをゼロから学習させ、鏡面特有の一般的な視覚的特徴 (光の反射特性や枠の形状など) の表現を獲得させることを目的とした。

次に事前学習済みのモデルを用いてファインチューニングを実施する。事前学習で獲得した重みを初期値として読み込み、実機ロボットが稼働する対象環境で取得した独自データセットを用いて微調整を行なった。

このアプローチにより、一般的な鏡の概念を維持しつつ、実環境に特化した高精度な検出モデルを構築した。

3) 損失関数とクラス不均衡への対策

学習時の損失関数 (Loss Function) には、ピクセル単位の分類誤差を評価する BCE (Binary Cross Entropy) Loss と、予測領域と正解領域の空間的な重なりを評価する Dice Loss を組み合わせた「ComboLoss」を採用した。

さらに、画像全体のピクセル数に対して鏡面領域 (正例) のピクセル数が極端に少ないというクラス不均衡の問題に対処するため、学習時に動的な重み付けを行った。具体的には、使用するデータセットごとに正例と負例 (背景領域) のピクセル総数を集計し、その比率からポジティブウェイトを算出している。これを BCE Loss に適用することで、少数クラスである鏡面領域の未検出を強力に防ぐよう学習を最適化した。

4.2.2 実装環境

セグメンテーションモデルの構築および学習に使用したハードウェアおよびソフトウェアの環境を表 6 に示す。深層学習モデルの膨大な学習プロセスを高速化するため、GPU (CUDA) 環境を用いて実行した。また、ネットワークの構築には深層学習フレームワークである PyTorch を採用し、学習データの汎化性能を向上させるためのデータ拡張処理には Albumentations を、ハイパーパラメータの自動探索には Optuna をそれぞれ使用した。

表 6 セグメンテーションモデルの実装環境

使用機器・ソフトウェア	型番・バージョン
デスクトップ PC	-
OS	Ubuntu 22.04
CPU	Intel Core i7-8700K
GPU	NVIDIA GeForce RTX 4070 Ti SUPER
メモリ	64GB
Visual Studio Code	1.107.0
JupyterLab	4.1.2
GPU ドライバ	560.35.05
CUDA	12.6
Python3	3.10.12
Python ライブラリ	NumPy 1.26.4 PyTorch 2.2.1+cu121 Matplotlib 3.10.3 OpenCV 4.11.0 Optuna 4.7.0 Pillow 10.3.0 tqdm 4.66.2 Albumentations 2.0.5

4.2.3 データセットの構築

本研究で提案する 2 段階の学習アプローチ（事前学習およびファインチューニング）を実現するため、目的に応じて 2 種類のデータセットを用意した。

4.2.3.1 事前学習用公開データセット

鏡面特有の一般的な視覚的特徴（光の反射、枠の形状など）を獲得させるため、既存の公開データセットである MSD[34], PMD[35], 3DRef_mirror[36]から計 8,454 枚の画像を抽出し、事前学習用データセットとして構築した。大規模かつ多様な環境下で撮影された画像を事前学習に用いることで、特定の照明条件や背景に依存しないモデルの汎化性能の向上を図った。

4.2.3.2 ファインチューニング用独自データセット

実際のロボット稼働環境にモデルを適合させるため、RealSense で撮影された RGB 映像データを収集し、以下の方法で学習画像の選定とアノテーションを実施して独自データセットを作成した。

まず、取得した RGB 映像データの全フレームを画像として保存し、そこから平均二乗誤差（MSE）に基づき類似画像を削除することで、学習に有効な多様なシーンの画像のみを抽出した。RGB 画像をグレースケール化および 32×32 へのリサイズを行い、画素数を $[0,1]$ の範囲に正規化した上で、以下の式(4.1)を用いて MSE の計算を行う。

$$MSE = \frac{1}{HWC} \sum_{c=1}^C \sum_{y=1}^H \sum_{x=1}^W (I_1(x, y, c) - I_2(x, y, c))^2 \quad (4.1)$$

ここで、 I_1 と I_2 は比較する 2 枚の画像、 H と W は画像の高さと幅、 C はチャンネル数である。

既にユニーク（アノテーション対象に採用）と判定された画像と比較し、MSE が 0.01 以下のものがあれば「類似」と判定してアノテーション対象から除外し、どのユニーク画像とも似ていなければアノテーション対象へ採用した。

その後、アノテーションツール CVAT を用いてセグメンテーションマスク画像を作成した。作成したデータセットの概要を表 7 に示す。

表 7 データセットの概要

項目	内容
画像枚数	1209 組 (RGB 1209 + Mask 1209)
画像形式	PNG
解像度	640×480 : 861 枚, 1280×720 : 348 枚
マスク値	$[0, 255]$ の 2 値 (背景=0, mirror=255)

実際のデータセットの画像例を図 8, 図 9 に示す。



図 8 データセットの例 (640×480)




図 9 データセットの例 (1280×720)

4.2.4 モデルの事前学習

本節では、鏡面の一般的な視覚的特徴を獲得させるための事前学習 (Pre-training) のプロセスについて述べる。事前学習には、前節で構築した公開データセット由来の 8,454 組の画像を用いた。

4.2.4.1 前処理およびデータ拡張

ネットワークへの入力画像は 512×512 ピクセルにリサイズし、ImageNet データセットの平均値 (0.485, 0.456, 0.406) と標準偏差 (0.229, 0.224, 0.225) を用いて正規化を行った。また、モデルの汎化性能を向上させるため、学習時には Albumentations ライブラリを用いて、左右反転、シフト・スケール・回転、輝度・コントラストの変更、およびガウシアンノイズの付加といったデータ拡張 (Data Augmentation) を適用した。

4.2.4.2 クラス不均衡への対策と損失関数の定式化

画像全体のピクセル数に対して鏡面領域 (正例) のピクセル数が極端に少ないクラス不均衡の課題に対処するため、損失関数には BCE Loss (L_{bce}) と Dice Loss (L_{dice}) を組み合わせた ComboLoss を採用した。ComboLoss は以下の式で表される。

$$Loss = w_{bce} \times L_{bce} + w_{dice} \times L_{dice} \quad (4.2)$$

ここで、 w_{bce} と w_{dice} はそれぞれの損失に対する重みであり、 $w_{bce} + w_{dice} = 1$ を満たす。さらに、事前学習データセットに含まれる正例ピクセル (約 6.4 億) と負例ピクセル (約 55 億) の比率から算出したポジティブウェイト 8.515 を L_{bce} に適用した。これにより、少数クラスである鏡面領域の未検出に対して大きなペナルティを与え、学習の偏りを防いだ。

4.2.4.3 ハイパーパラメータ探索と学習手順

最適化アルゴリズムには Adam を使い、バッチサイズを 10、最大エポック数を 60 に設定して学習を行った。学習過程において、検証データに対する IoU (Intersection over Union) を監視し、15 エポック連続で改善 (閾値: 1.0×10^{-4}) が見られない場合には学習を打ち切る Early Stopping (patience=15) を導入した。

本学習では、検証 IoU を最大化することを目的関数とし、Optuna を用いて 15 回のトライアルを実行してハイパーパラメータの自動探索を実施した。探索の結果、最も精度の高くなった最適なパラメータは以下の通り決定された。

- 学習率 : 1.12×10^{-4}
- Dropout 率 : 0.013
- Bottleneck Dropout 率 : 0.398
- 損失関数の重み比率 : $w_{bce} = 0.659$, $w_{dice} = 0.341$

また、このトライアルにおいて最適化されたデータ拡張の適用確率は、左右反転が約 69.3%、シフト・スケール・回転が約 17.1%、ノイズ付加が約 21.7%であった。これらの最適パラメータを用いて学習を完了させ、最高精度を記録したエポックの重みを事前学習済みモデルとして保存した。この重みは、次節のファインチューニングにおけるネットワークの初期値として利用される。

最適なハイパーパラメータを用いて学習を行った際の学習曲線（Learning Curve）を図 10 に示す。図から、学習の初期段階においては学習データ（Train）および検証データ（Validation）の Loss がともに順調に減少し、IoU が向上していることがわかる。




図 10 事前学習の学習推移グラフ

その後、エポックが進むにつれて Train のスコアは向上し続ける一方で、Validation のスコアとの間に乖離（汎化ギャップ）が生じ始め、モデルが学習データに過剰に適合していく過学習（Overfitting）の傾向が見られた。本学習は設定した最大エポックまで進行したが、学習過程において毎エポックの Validation IoU を監視しており、最も汎化性能が高かった時点（49 エポック目）の重みを最適モデルとして保存・採用した。これにより、過学習が進行した最終エポックの重みではなく、最も汎用的に鏡面を抽出できる状態のモデルを獲得した。

4.2.5 モデルのファインチューニング

本節では、事前学習で獲得した一般的な鏡面の視覚的特徴をベースとして、実際のロボット稼働環境（対象環境）に適合させるためのファインチューニング（微調整）のプロセスについて述べる。学習には、4.2.3 節で構築した独自データセットの学習用データ（846 組）および検証データ（181 組）を用いた。

4.2.5.1 データ拡張およびクラス不均衡への適応

独自データセットは公開データセットと比較してデータ数が限られているため、学習時の過学習を抑制することが必要である。そのため、事前学習と同様に Albumentations を用いた強力なデータ拡張（左右反転、シフト・スケール・回転、輝度・コントラスト調整、ノイズ付加など）を適用し、見かけのデータ多様性を向上させた。

また、対象環境におけるクラス不均衡に適応するため、独自データセットを用いてポジティブウェイトの再計算を行った。独自データセット内の正例ピクセル（約 4,652 万）と負例ピクセル（約 4 億 2,256 万）の集計から、9.083 と算出された。これを ComboLoss の BCE

Loss に適用することで、対象環境特有の背景に対して鏡面領域の未検出をより強力に防ぐよう損失関数を最適化した。

4.2.5.2 転移学習とハイパーパラメータの再探索

ネットワークの重みの初期値には、前節で獲得した事前学習済みモデルの重みを読み込んだ。最適化アルゴリズムには Adam (Weight Decay: 1.0×10^{-4}) を用い、バッチサイズを 10、最大エポック数を 80 に設定した。

ファインチューニングにおいては、事前学習で得た特徴表現を破壊しないよう、事前学習時よりも小さな学習率を設定するなどの微調整が求められる。本研究では、対象環境に最適なパラメータを客観的に決定するため、事前学習の際と同様に Optuna を用いて 15 回のトライアルを実行し、ファインチューニングに特化した学習率、Dropout 率、および ComboLoss の重み比率 (w_{bce}, w_{dice}) の再探索を行った。

4.2.5.3 学習結果と最終モデルの保存

各エポックの終了時には、検証データ (Validation Set) に対して固定閾値 0.5 で二値化を行い、IoU を算出して汎化性能を監視した。事前学習時と同様に、15 エポック連続で検証 IoU の改善が見られない場合に学習を打ち切る Early Stopping (patience=15) を適用した。Optuna による探索および学習の結果、最終的に 65 エポック目で検証 IoU が最高値 0.9499 を記録して学習が完了した。この最も対象環境への適合度が高かった時点のモデルの重みを、最終的な推論用モデルとして保存した。

ファインチューニング実行時の学習曲線を図 11 に示す。事前学習済みの重みを初期値として用いているものの、学習の初期エポックにおいては、独自データセット (対象環境) の特有の背景や照明条件に適応する過程で、一時的に Validation の Loss が高く (IoU が低く) 推移していることがわかる。




図 11 ファインチューニングの学習推移グラフ

しかし、エポックが進むにつれてモデルは対象環境のデータ特性に適合し、Train と Validation の双方で順調に精度が向上した。本フェーズにおいても最大エポックまで学習

が完走したが、過学習（汎化ギャップの拡大）が進行する前の、Validation IoU が最大となった時点（50 エポック目）の重みを最終的な推論用モデルとして採用した。これにより、限られた独自データセットにおける過学習の影響を排除しつつ、対象環境に適合したモデルを構築できたことが確認できる。

4.3 鏡面再構成システムの実装

4.3.1 システム概要

本システムは ROS 2 上で動作する複数のノード群によって構成され、各ノードはトピック通信および TF（Transform）を介してデータをやり取りする。主要なノード構成を示す概要図を図 12 に示す。




図 12 鏡面再構成システムの概要図

- カメラノード: RealSense を起動し、RGB 映像・Depth 映像・IMU 信号を出力する。
- SLAM ノード: RealSense のデータを元に RTAB-Map を実行し、三次元地図データを構築する。
- セグメンテーション推論ノード: 学習済みモデルを用いて入力画像から鏡面領域のマスクを生成する。
- マーカー検出ノード: 鏡面に映り込んだ AprilTag（虚像）を検出する。
- 鏡面位置計算ノード: 鏡像マーカーと実マーカーの幾何学的関係から、鏡面の 3 次元平面パラメータを推定する。
- 鏡面位置クラスタリング・出力ノード: 推定された平面パラメータを地図座標系上でクラスタリングし、安定した鏡面パラメータを推定・保持する。
- 鏡面再構成ノード: 画像上の鏡面マスクを、推定された 3 次元平面上へポリゴンとして投影する。

4.3.2 実装環境

本システムの開発および動作検証は表 8 に示す環境にて行った。

表 8 鏡面再構成システムの実装環境

使用機器・ソフトウェア	型番・バージョン
デスクトップ PC	-
OS	Ubuntu 22.04
CPU	Intel Core i7-8700K
GPU	NVIDIA GeForce RTX 4070 Ti SUPER
メモリ	64GB
Visual Studio Code	1.107.0
ROS 2	Humble
GPU ドライバ	560.35.05
CUDA	12.6
Python3	3.10.12

4.3.3 モデルのデプロイ

セマンティックセグメンテーションによる鏡面検出はセグメンテーション推論ノードに実装した。本ノードは、初期化時に指定されたパスから学習済みの U-Net モデル (PyTorch 形式 .pt ファイル) を読み込み、GPU (CUDA) 上に展開する形とした。

カメラから取得した RGB 画像は、モデルの入力サイズである 512×512 ピクセルにリサイズされ、ImageNet の平均・分散を用いた正規化処理が行われる。推論結果として得られる確率マップは、閾値 0.5 で二値化された後、元の画像サイズにリサイズされ、鏡面領域を表すバイナリマスク画像として出力される。これにより、入力フレームと同等のリアルタイム処理を実現した。

4.3.4 マーカー検出

鏡像マーカーの検出には、標準的なライブラリである `apriltag_ros` パッケージを利用した。本研究では Tag36h11 ファミリーの AprilTag を使用し、鏡面に映り込んだタグ (虚像) のカメラ座標系における姿勢 T_{virt} を検出する。

一方、ロボット本体に固定された実マーカーの姿勢 T_{real} については、カメラに対する相対位置・姿勢が不変であるため、静的な TF (Static Transform) として配信する設計とした。これにより、カメラ座標系において実像と虚像の双方の位置関係を常に参照可能な状態としている。

4.3.5 鏡面位置の特定

単一フレームにおける鏡面パラメータの推定は鏡面位置計算ノードに実装した。本ノードは、TF ツリーからカメラ座標系における実マーカー T_{real} と虚像マーカー T_{virt} の変換

行列を取得する.

提案手法で述べた理論に基づき, 反射変換行列 $S = T_{virt} \cdot T_{real}^{-1}$ を算出し, その回転成分から鏡面の法線ベクトル n を, 並進成分から原点距離 d を復元する.

算出された平面パラメータ $\pi = [n_x, n_y, n_z, d]^T$ は, メッセージとして出力される. また, 誤検出を除外するため, 法線ベクトルがカメラ方向を向いていない場合や, 実像と虚像の距離が極端に離れている場合は, 推定結果を破棄するフィルタリング処理を実装した.

4.3.6 データのクラスタリング

フレーム毎に推定される平面パラメータにはセンサノイズによるばらつきが含まれるため, 鏡面位置クラスタリング・出力ノードにおいて時系列クラスタリングを行う. 本実装では, Whelan ら[5]が提案した DP-Means 法を応用した逐次的なクラスタリングアルゴリズムである DP-Plane を採用した. 新たに観測された平面パラメータに対し, 既存のクラスタ中心との距離(法線方向および位置の偏差)を評価し, 閾値(dp_lambda, デフォルト 0.1m)以内のクラスタが存在すれば統合・更新を行う. 閾値内に適合するクラスタが存在しない場合は, 新たな鏡面クラスタとして登録する. 各クラスタは, 観測回数が一定値を超えた場合にのみ「有効な鏡面」と判定され, その平均化された平面パラメータが後段の投影プロセスへ送られる. これにより, 一時的な誤検出やノイズの影響を排除し, 環境内に実在する鏡面のみを安定して保持することが可能となる.

4.3.7 SLAM マップへの投影

推定された鏡面クラスタに対し, 画像上の鏡面領域を投影して 3 次元的な占有領域を生成する処理は, 鏡面再構成ノードとして実装した.

1) レイキャスティングによる投影

セマンティックセグメンテーションによって得られたマスク画像の各画素に対し, カメラ原点からのレイ(視線ベクトル)を生成する. このレイと, 推定された鏡面平面(無限平面)との交差判定を行い, 3次元空間上の交点を算出する.

2) グリッドベースの集約とポリゴン生成

前段の処理で得られるのは疎な点群であるため, これを集約したポリゴンを生成する. 鏡面クラスタごとに局所的な 2 次元グリッドマップを定義し, 投影された点がどのグリッドセルに含まれるかをカウントする. 一定時間蓄積された投票数(密度)が閾値を超えた領域に対し輪郭抽出を行い, 最終的な鏡面の形状を表す 3 次元ポリゴンを生成する. このポリゴンは Visual SLAM の地図上において障害物として扱われ, ロボットのナビゲーション層へと引き渡されることを想定している.

第5章 評価

5.1 評価概要

本章では、第4章で実装した提案システムが、本研究の目的である「鏡面反射に起因する Visual SLAM の地図破綻を防ぎ、安全なナビゲーションを実現する」という課題に対して、どの程度有効に機能するかを検証・評価する。システムの各モジュールからシステム全体の動作に至るまで、多角的な視点から評価を行うため、本章は大きく以下の3つの段階に分けて評価を展開する。

第一に、5.2節では「セマンティックセグメンテーションによる鏡面検出精度」を評価する。学習プロセスに一切使用していないテストデータセットを用いた定量評価 (IoU, Recall などの算出) により、モデルの基本的な汎化性能を示す。さらに、学習したモデルを実機システムに組み込み、静止状態および移動ロボットの走行状態における推論結果の定性評価を実施する。これにより、実環境の動的な変化 (距離やブレなど) に対する鏡面抽出の安定性と課題を明らかにする。

第二に、5.3節では「鏡面の三次元再構成精度」を定量的に評価する。抽出された鏡面領域と AprilTag の幾何学関係から推定された「鏡面の方程式 (法線ベクトルおよび距離)」が、現実の空間構造に対してどの程度正確であるかを、正解データ (Ground Truth) との比較により検証する。また、推定結果に基づいて三次元空間上に投影された鏡面ポリゴン (点群) の形状誤差 (Chamfer 距離) や投影精度 (IoU) を算出し、本手法がセンチメートル単位の高精度な再構成能力を持つこと、およびセンサノイズに対してロバストに機能することを証明する。

最後に、5.4節では「Visual SLAM への統合とナビゲーション応用の評価」を行う。前節までに精度の有効性が確認された鏡面パラメータに基づき、生成された鏡面ポリゴンを RTAB-Map による三次元地図データへと統合した結果を定性的に確認する。さらに、ROS 2 のナビゲーションパッケージ (Nav2) を用いたローカルコストマップ上において、投影された鏡面ポリゴンが前方の物理的な障害物として正しく判定・反映されるかを検証する。これにより、本手法による再構成結果が、ロボットのナビゲーション用地図として実用上十分な整合性を持っているかを評価する。

5.2 セマンティックセグメンテーションによる鏡面検出

本節では、第4章で構築・学習した U-Net ベースのセグメンテーションモデルに対して、学習プロセスに一切使用していないテストデータを用いた性能評価を行う。評価は、数値指標を用いた定量評価と、出力画像を視覚的に確認する定性評価の両面から実施した。なお、確率マップを二値化する際の閾値は 0.5 に設定している。

5.2.1 モデルの定量評価

独自データセットから分割したテストデータ（61 組）に対する推論を行い、モデルの汎化性能を定量的に評価した。評価指標として、Loss, IoU (Intersection over Union), Precision, Recall, および F1-score を用いた。テストデータセットを用いて算出した最終的な定量評価結果を表 9 に示す。

表 9 テストデータに対する各種評価指標の数値

評価指標	結果
Loss	0.0583
IoU	0.9194
Precision	0.9683
Recall	0.9359
F1-Score	0.9368

結果として、IoU が約 0.919, Recall (再現率) が約 0.936 という高い水準を達成した。Recall が高いことは、実際の鏡面領域を見逃さずに検出できていることを意味しており、後段の Visual SLAM において「鏡像を実空間と誤認して地図に組み込んでしまう」という致命的なエラーを防ぐ上で、非常に有効な精度が確保できていると言える。

加えて、本システムの実用性を検証するため、推論速度の計測を行った。実験環境 (GPU: RTX 4070Ti Super) において、入力画像サイズ 512×512 での推論処理時間は平均約 12.5 ms であり、フレームレートは入力が 25.3 FPS に対し、出力で 24.7 FPS を達成した。これは、ロボットの制御周期に対して十分に高速であり、リアルタイムなナビゲーションに適用可能であることを示している。

5.2.2 実環境における検出結果

次に、学習したモデルを実際のシステムに組み込み、出力された予測マスク画像を用いて定性的な評価を行った。まず、テストデータセットに対する推論結果の一例を図 13 に示す。

1758950790807153564.png



GT



Pred@0.35



1752906456304338135.png



GT



Pred@0.35



175894979005358867.png



GT



Pred@0.35



図 13 テストデータに対する推論結果

次に、静止状態のロボットから鏡面を観測した結果の一例を図 14 に示す。図から、静止状態かつ環境が比較的単純な条件下においては、鏡面の境界を正確に捉え、対象領域を高い精度で抽出できていることが確認できる。



図 14 静止状態での推論結果

一方で、移動ロボットを実際に走行させつつ鏡面のセグメンテーションを実施した際の推論結果の一例を図 15 に示す。図 15 から明らかなように、走行状態におけるセグメンテーション結果には不安定さが目立つ結果となった。具体的には以下の 2 点の課題が観察された。

- 1) 距離による検出漏れ：ロボットと鏡面からの距離が遠すぎる場合、マスク画像に鏡面の領域が正しく反映されない（未検出）ケースが発生した。
- 2) 近接時の形状崩れ：鏡面との距離が近い場合であっても、推論された領域内の一部に欠損が生まれ、鏡面枠の外側へ領域がはみ出す誤ったセグメンテーション（過検出）が見られた。




図 15 走行状態での推論結果

これらの結果から、テストデータセット上の定量評価では高い数値を示したものの、実機による動的な環境下（走行時のブレや照明変化、映り込みの複雑化など）においては、セグメンテーションの安定性に課題が残ることが明らかとなった。

5.3 鏡面位置推定精度の定量評価

5.3.1 実験条件と真値の定義

提案システムによる鏡面パラメータ（法線ベクトルおよび距離）の推定精度を検証するため、静止状態における定量評価実験を行った。真値（Ground Truth）の取得には、鏡の四隅に配置した4つのAprilTagを使用した。これら4点の三次元座標の平均値を鏡の中心位置、および各マーカの法線ベクトルの平均を鏡の真値法線と定義し、提案手法によって推定された無限平面との幾何学的誤差を検証した。計測には、鏡に対して正対するロボットの距離を0.5mから2.0mまでの範囲で変化させ、それぞれの位置で数分間のデータを取得した。また、実験に使用したロボットは鏡面との高さを合わせるため、モバイルPCを取り外し、カメラの位置を調節した。実験の様子を図16に示す。




図 16 実験の様子

5.3.2 距離および法線ベクトルの推定精度

距離推定精度の結果を図17に、法線方向推定精度の結果を図18に示す。グラフの縦軸は真値との誤差、横軸は鏡までの距離を表しており、角プロットは計測期間中の平均値、エラーバーは標準偏差を示している。また、各条件における数値結果を表10にまとめる。




図 17 距離推定精度の実験結果




図 18 法線方向推定精度の実験結果

表 10 位置推定実験の結果

距離 [m]	絶対距離誤差 [mm] (平均 ± 標準偏差)	法線角度誤差 [deg] (平均 ± 標準偏差)	サンプル数 (N)
0.5	2.17 ± 2.33	1.62 ± 0.07	2,878
0.6	3.21 ± 0.34	1.47 ± 0.16	4,216
0.7	7.04 ± 1.13	2.65 ± 0.15	2,808
0.8	0.52 ± 0.36	3.46 ± 0.09	2,265
0.9	1.67 ± 1.13	0.81 ± 0.31	3,370
1.0	0.98 ± 1.14	3.33 ± 0.27	2,314
1.1	1.10 ± 1.57	4.06 ± 0.28	1,235
1.2	15.34 ± 0.40	6.04 ± 0.13	1,274
1.3	5.91 ± 2.01	4.54 ± 0.44	2,349
1.4	18.60 ± 0.51	5.03 ± 0.25	5,705
1.5	17.51 ± 6.06	5.83 ± 1.07	3,660
1.6	21.96 ± 7.41	6.63 ± 1.33	10,596
1.7	18.67 ± 14.58	6.65 ± 1.40	1,707
1.8	19.67 ± 16.17	6.83 ± 1.25	1,857
1.9	22.48 ± 21.44	7.82 ± 1.19	5,513
2.0	13.60 ± 8.66	9.39 ± 1.53	86

距離 0.5 m から 1.1 m の範囲では、距離推定誤差が平均 2.4 mm 以下（最大でも 0.7 m 地点の約 7.0 mm）という高い精度が得られた。法線角度も同様にこの範囲においては 5 度以下という精度が得られた。一方で、距離が 1.2 m を超えると距離誤差は約 15 mm ～ 22 mm へと急増し、法線ベクトルの角度誤差も距離 2.0 m 地点では約 9.4 度まで増大した。

5.3.3 再構成点群の投影精度の定量評価

前節では，生成された鏡面ポリゴンが三次元地図上で定性的に整合していることを確認した．本節では，提案手法によって推定・投影された三次元の鏡面点群が，実際の鏡面領域をどの程度正確に覆えているか，またその精度が連続するフレームにおいてどの程度安定しているかを定量的に評価する．

1) 評価データの測定

評価データは静止した移動ロボットのカメラから壁面と並行になるよう設置した鏡面を撮影したデータを用いた．評価データは鏡面をそのまま撮影したものと，鏡面を紙で覆ったものの2種類を用意し，それぞれから得られたデータを比較することで定量評価を実施した．

図 19 は鏡面をそのまま撮影したシステムを実行する推論用の RGB 画像データである．




図 19 推論用の実験データの RGB 画像

システムで鏡面に映り込む移動ロボットの AprilTag を捉えるだけでなく，鏡面の背後にある壁面に貼られた AprilTag も同時に観測することで，鏡面の壁面との位置関係を記録した．

図 20 は鏡面に紙を貼り付け鏡面位置の正解として撮影した RGB 画像データである．




図 20 鏡面位置の正解データの RGB 画像

図 19 と同様の撮影環境のまま鏡面全体を覆う紙で覆った．この紙には四隅と中央に AprilTag を配置し，鏡面の領域とカメラからの距離を計測できるようにしている．

これらの二つの撮影データから本研究で提案されるシステムによる推定結果と AprilTag を利用して計測した鏡面の正しい位置データを比較することで，定量評価を実施した．

2) 全体精度の評価

評価指標として，正解の鏡面領域に対する推定点群の IoU (Intersection over Union), F1-score, Recall, および三次元的な形状誤差を示す Chamfer 距離 (mm) を用いた．また，センサノイズによる極端な外れ値（上位 2% のノイズ点群）を除外した状態で評価メトリクスを算出した．データセット全体を通した評価結果を表 11 に示す．

表 11 各種評価指標による計測結果

評価指標	平均値	中央値
IoU	0.943	0.955
F1-score	0.970	0.977
Precision	0.959	0.966
Recall	0.982	0.988
Chamfer 距離[mm]	9.19	7.13
面積比 (Area Ratio)	1.024	1.022

結果として，投影された点群の IoU は平均 0.943, Recall は平均 0.982 という極めて高

い精度を達成した。面積比 (Area Ratio) が平均 1.024 であることから、実際の鏡面領域をわずかに (約 2.4%) 大きく覆う形で再構成できていることがわかる。これは、ロボットのナビゲーションにおいて鏡面への衝突を防ぐ「安全マージン」として機能するため、望ましい結果であるといえる。

また、再構成点群の形状誤差を示す Chamfer 距離は平均 9.19 mm (中央値 7.13 mm) であり、センチメートル未満の誤差で三次元空間上に投影できていることが確認された。なお、この評価データセット全体における鏡面方程式の推定誤差 (全体平均) は、角度誤差 2.23 度、距離誤差 14.56 mm であり、前節までの結果を裏付ける安定した精度が示された。

3) センサノイズに対する安定性 (時系列推移) の評価

セグメンテーションモデルの推論結果や深度センサの計測値は、カメラが静止している状態であっても、環境光の微小な変化やセンサ特有のノイズによってフレームごとに揺らぎ (ジッタ) が生じる。そこで、本手法が連続するフレームにおいてどの程度安定した投影精度を維持できるかを評価した。図 21 に、連続フレームにおける投影 IoU の時系列推移を示す。




図 21 再構成点群の IoU の時系列推移

図 21 から、全フレームを通じて IoU が 0.8 以上の高い水準で安定して推移していることがわかる。これにより、本手法による三次元投影はフレームごとの微小なノイズに対して破綻することなく、静止状態のベースラインとして十分に堅牢 (ロバスト) に機能していることが証明された。

4) 点群投影の定性的な評価

さらに、実際の二次元画像平面 (UV 空間) 上において、正解の鏡面領域と推定された点群がどのように重なっているかを可視化した結果を図 22 に示す。




図 22 鏡面領域に対する推定点群の投影結果

図 22 において、黒色の破線が正解となる鏡面領域の枠、水色の点が正常に投影された推定点群（インライア）、赤色の点がフィルタリングにより除外されたノイズ点（アウトライア）を示している。図が示す通り、推定された点群は正解領域の枠をほぼ正確に捉えており、U-Net のセグメンテーション誤差やセンサ起因の外れ値が適切に除外され、有効な三次元情報のみが再構成に利用されていることが確認できる。

5.4 Visual SLAM への統合とナビゲーション応用の評価

提案手法によって推定された鏡面パラメータに基づき、三次元空間上に生成された鏡面ポリゴンの様子を図 23 に示す。図 19 の推論用のデータを用いて Visual SLAM と鏡面の三次元再構成を実行し、推定された鏡面領域は橙色で囲われた領域である。




図 23 生成された鏡面ポリゴン

この結果から、実環境における鏡の位置および姿勢と、再構成されたポリゴンが高い精度で一致していることがわかる。特に、従来の Visual SLAM が検出できていなかった鏡面による奥行き方向に展開されてしまう虚像領域の手前に正しく投影できていることが確認できる。

また、この鏡面ポリゴンの投影前後で障害物判定に違いがあるのかを実験した。図 24 では ROS 2 のナビゲーションパッケージである Nav2 を用いて周辺の障害物をコストマップとして表示した結果である。上部の画像がシステム実行前、下部の画像がシステム実行後に鏡面を表すポリゴンが出現した時である。




図 24 Nav2 によるローカルコストマップを用いた障害物判定

システム実行前では鏡面を捉えられていないため、ローカルコストマップは鏡面後方にある壁面だけを障害物(ピンクと水色の領域)として認識している。しかし、本研究で提案するシステムを実行することで、鏡面ポリゴンが壁面の前方に現れ、その場所も障害物として判定されていることがわかる。

以上の結果より、提案手法は幾何学的な数値精度だけでなく、ロボットのナビゲーション用地図としての整合性も十分に確保できているといえる。

第6章 考察

6.1 システムの有効測定範囲と走行安全性

5.3.2 節の実験結果より、本システムが鏡面位置をミリメートル単位の高精度で推定できる範囲は、鏡から約 1.1 m 以内であることが確認された。1.2 m を超えると推定誤差が増大する傾向にあるが、この「有効半径 1.1 m」という範囲は、屋内自律移動ロボットの安全性確保において実用上十分な距離であると考えられる。一般的な屋内環境において、ロボットの移動速度は安全のために低速（例えば 0.2~0.5 m/s 程度）に制限されることが多い。鏡の存在を 1.1 m 手前で認識できれば、ロボットは衝突までに数秒の猶予を持つことができ、減速や停止、あるいは回避経路の再計算を行うのに十分な時間を確保できる。したがって、遠距離からの検出精度が低下するという制限はあるものの、ロボットが鏡に接近し、衝突するリスクを未然に防ぐという本研究の主目的においては、十分な性能を有していると結論付けられる。

6.2 キャリブレーション誤差の影響と斜め方向からの観測における課題

5.3.2 節で示した 0.5 m から 1.1 m の高精度な推定範囲においても、数 mm 程度の一定の距離誤差（オフセット）が生じていることが確認された。グラフの標準偏差（エラーバー）が極めて小さいことから、このズレはアルゴリズムの確率的な揺らぎによるものではなく、システムに内在する固定的な誤差に起因すると考えられる。具体的には、4.1.4 節で実施した「カメラと実像マーカー間の相対位置 (T_{real})」の物理的な手計測における数ミリの測定誤差が、鏡面位置の計算結果に直接的な定常誤差として伝播している可能性が高い。Visual SLAM において重要なのは計測値の時間的安定性であるため、この定常的なズレ自体は致命的ではないが、より厳密なキャリブレーション手法を導入することで、さらなる絶対精度の向上が可能であると考えられる。

また、本研究における定量評価は、ロボットが鏡面に対して正対（進入角度 0 度）した状態を前提として実施された。しかし、実際の屋内ナビゲーションにおいては、ロボットが斜め方向から鏡面に接近するケースも多々発生する。斜め方向から観測した場合、光の反射の法則により、ロボットに搭載されたマーカーが鏡面に映り込む条件が幾何学的に厳しくなる。そのため、進入角度によっては鏡像マーカー（AprilTag）自体がカメラの視野に映り込まず、鏡面の三次元位置推定そのものが実行できなくなる問題が考えられる。したがって、より多様な環境で本システムを運用するためには、斜めからの進入時にもマーカーが確実に鏡面に映り込むような、マーカー配置の最適化が今後の課題となる。

6.3 静止状態と走行状態によるセグメンテーション精度の違い

本研究における鏡面領域の投影精度に関する定量評価（5.3.4 節）は、真値取得の制約から、移動ロボットが静止した状態で実施された。一方で、5.2.2 節の定性評価で示した通り、実機が走行している状態においては、カメラ映像のモーションブラーや照明条件の動的な変化が生じ、セグメンテーションの推論結果に未検出や形状崩れといった不安定さが確認

された。

この精度の乖離は、学習モデルの汎化能力の不足が原因であると考えられる。本研究のモデル学習に用いたデータセット（独自・公開）の多くは、被写体ブレのない比較的鮮明な静止画像で構成されており、移動ロボット特有の動的な映像ノイズ（露出の急変やブラーなど）を十分に網羅できていなかった。今後の課題として、実機走行時の映像から意図的にノイズを含む画像を抽出してデータセットを拡充する、あるいは複数フレームにわたる推論結果を時間軸で平滑化するトラッキング処理を導入することで、走行状態におけるセグメンテーション精度の向上が見込まれる。

6.4 複数地点での鏡面観測におけるループクロージングの破綻

移動ロボットを用いた Visual SLAM において、鏡面環境が与える深刻な悪影響の一つとして、鏡像反射に起因する「誤ったループクロージング」の発生が挙げられる。一般に、RTAB-Map や ORB-SLAM などのシステムは、現在のカメラ画像から抽出した視覚的特徴量を過去のデータベースと照合し、「過去に訪れた場所と同じ場所に戻ってきたか」を判定することで、蓄積した自己位置推定誤差を補正する。

しかし、鏡が存在する環境においてロボットが移動する場合、鏡には常に「ロボット自身の姿」や「搭載されたマーカー」が虚像として映り込む。ロボットが異なる 2 地点から同じ鏡を観測した際、鏡面上の背景は視点移動に伴って変化するが、鏡に映るロボット自身の外観的特徴は不変である。このとき、場所認識アルゴリズムは、異なる地点の画像内に共通して存在する「ロボットの鏡像特徴」を強力なランドマークとして誤認し、実際には離れた場所にいるにもかかわらず「同じ場所にいる」と誤判定して、ポーズグラフ上に誤った拘束（エッジ）を追加してしまう。

このような誤ったループクロージングが発生すると、最適化処理によって地図全体が強制的に歪められ、本来あり得ない位置にロボットの軌跡が修正される現象が引き起こされる。なお、本研究で構築したシステムは Visual SLAM と独立して動作する構成であるため、SLAM 内部の特徴点抽出に対するマスキングなどの除外処理は実施していない。開発過程においても、鏡に映った自己像を介して地図が破綻する傾向が確認されたが、これらがループクロージングに与える影響の詳細は未検証の仮説にとどまっている。しかし、本研究のような Visual SLAM と独立させたシステムで地図上に障害物を追加するだけでは、ループクロージングの誤判定に起因する地図破綻を防ぐことは困難であると考えられる。したがって、真にロバストな地図構築を実現するためには、本手法で得られた鏡面領域（マスク画像）を利用し、Visual SLAM 内部の特徴点処理に直接介入して鏡像特徴を処理プロセスから除外する仕組みの統合が今後の課題となる。

第7章 結論

本研究では、自律移動ロボットの Visual SLAM における鏡面反射に起因する地図破綻やナビゲーションの失敗を解決するため、単眼カメラ画像のみから鏡面の三次元位置および姿勢を推定し、環境地図へ統合する手法を提案した。既存手法のような高価な追加センサに依存せず、U-Net を用いたセマンティックセグメンテーションと、鏡面に映る AprilTag の幾何学的拘束（実像と虚像の関係）を組み合わせることで、環境の事前情報なしに鏡面領域を三次元空間上の障害物として再構成するシステムを構築した。

実機を用いたシステムの定量および定性評価により、提案手法の有効性が明確に示された。二次元の鏡面領域抽出においては、IoU 0.919 という高いセグメンテーション精度を達成し、推論速度も約 24.7 FPS とリアルタイムなナビゲーションに十分な性能を示した。三次元再構成の評価においては、まずカメラからの距離に応じた推定実験を行い、約 1.1 m 以内の範囲において誤差数 mm 程度という高精度な位置推定を実現した。さらに、点群の投影精度を検証したデータセット全体を通して、法線ベクトルの角度誤差が平均 2.23 度、距離誤差が平均 14.56 mm と安定しており、推定された鏡面方程式に基づく三次元投影点群は、実際の鏡面領域を IoU 0.943 の精度で適切に覆うことが確認された。これを RTAB-Map による環境地図に統合し、Nav2 のローカルコストマップ上に物理的な障害物として反映させることで、ロボットが鏡像を実空間と誤認して衝突するリスクを回避できることが実証された。

一方で、実機運用および評価を通じて、システムの限界と今後の課題も明確になった。第一に、静止状態では高精度な抽出が可能であったものの、ロボットの走行時にはモーションブラーや動的な照明変化により、セグメンテーション結果に未検出や形状崩れといった不安定さが確認された。第二に、本システムはロボットが鏡面に対して斜めから進入した場合、鏡像マーカー自体がカメラの視野に映り込まず、位置推定そのものが実行できなくなるという幾何学的な制約を抱えている。これらの解決には、動的ノイズを含む学習データの拡充や、マーカー配置の最適化によるロバスト性の向上が不可欠である。

さらに最も重要な課題として、本システムは Visual SLAM と独立して動作する構成であるため、鏡像特徴の誤認による「誤ったループクロージング」の根本的な解決には至っていない。真に安定した地図構築を実現するためには、本手法で得られた鏡面のマスク画像を Visual SLAM 内部の処理プロセスに直接フィードバックし、鏡像特徴を場所認識アルゴリズムから明示的に除外する仕組みの統合が必要である。

結びとして、本研究で提案した単眼カメラとマーカーを利用した幾何学的アプローチは、実装コストを抑えつつ実用的な精度で鏡面を障害物として認識・統合できる点で、屋内自律移動ロボットの安全性向上に寄与できる可能性を示した。本研究で得られた評価結果と課題の分析が、複雑な光学環境下における Visual SLAM 技術のさらなる発展に向けた一助となれば幸いである。

謝辞

本研究の遂行に際し，多岐にわたって御指導・御鞭撻を賜りました神戸英利教授に感謝申し上げます．また，研究の遂行と論文の完成において，多くの助言と御協力を頂きました神戸研究室の皆様に深く感謝し，心から御礼申し上げます．

参考文献

- [1] “三次元再構成 - 東京大学 先端科学技術研究センター 原田・黒瀬・椋田研究室.” Accessed: Jan. 01, 2026. [Online]. Available: https://www.mi.t.u-tokyo.ac.jp/research/3d_reconstruction
- [2] R. Szeliski, *Computer Vision: Algorithms and Applications*. in Texts in Computer Science. Cham: Springer International Publishing, 2022. doi: 10.1007/978-3-030-34372-9.
- [3] P. Herbert, J. Wu, Z. Ji, and Y.-K. Lai, “Benchmarking visual SLAM methods in mirror environments,” *Comput. Vis. Media*, vol. 10, no. 2, pp. 215–241, Apr. 2024, doi: 10.1007/s41095-022-0329-x.
- [4] I. Aydin, M. Yildiz, and E. Bayraktar, “Reflective Surface Detection and Its Impact on SLAM Trajectory Accuracy,” in *2025 7th International Congress on Human-Computer Interaction, Optimization and Robotic Applications (ICHORA)*, Ankara, Turkiye: IEEE, May 2025, pp. 1–6. doi: 10.1109/ICHORA65333.2025.11017079.
- [5] T. Whelan *et al.*, “Reconstructing scenes with mirror and glass surfaces,” *ACM Trans. Graph.*, vol. 37, no. 4, pp. 1–11, Aug. 2018, doi: 10.1145/3197517.3201319.
- [6] C. Cadena *et al.*, “Past, Present, and Future of Simultaneous Localization and Mapping: Toward the Robust-Perception Age,” *IEEE Trans. Robot.*, vol. 32, no. 6, pp. 1309–1332, Dec. 2016, doi: 10.1109/TRO.2016.2624754.
- [7] R. Mur-Artal, J. M. M. Montiel, and J. D. Tardos, “ORB-SLAM: A Versatile and Accurate Monocular SLAM System,” *IEEE Trans. Robot.*, vol. 31, no. 5, pp. 1147–1163, Oct. 2015, doi: 10.1109/TRO.2015.2463671.
- [8] M. Labbé and F. Michaud, “RTAB-Map as an open-source lidar and visual simultaneous localization and mapping library for large-scale and long-term online operation,” *J. Field Robot.*, vol. 36, no. 2, pp. 416–446, Mar. 2019, doi: 10.1002/rob.21831.
- [9] D. Damodaran, S. Mozaffari, S. Alirezaee, and M. J. Ahamed, “Experimental Analysis of the Behavior of Mirror-like Objects in LiDAR-Based Robot Navigation,” *Appl. Sci.*, vol. 13, no. 5, p. 2908, Feb. 2023, doi: 10.3390/app13052908.
- [10] Q. Mo, Y. Zhou, X. Zhao, X. Quan, and Y. Chen, “A Survey on Recent Reflective Detection Methods in Simultaneous Localization and Mapping for Robot Applications,” in *2023 6th International Symposium on Autonomous Systems (ISAS)*, Nanjing, China: IEEE, Jun. 2023, pp. 1–6. doi: 10.1109/ISAS59543.2023.10164614.
- [11] 谷口智生, 中泉文孝, and 井上雄紀, “深度センサを用いた鏡面検出手法の提案,” in 第

25 回日本バーチャルリアリティ学会大会論文集, Sep. 2020, pp. 2B3-6.

- [12] H. Sudo, S. Yukushige, S. Muramatsu, K. Inagaki, D. Chugo, and H. Hashimoto, “Detection of Glass Surface Using Reflection Characteristic,” in *IECON 2021 – 47th Annual Conference of the IEEE Industrial Electronics Society*, Toronto, ON, Canada: IEEE, Oct. 2021, pp. 1–6. doi: 10.1109/IECON48115.2021.9589219.
- [13] P.-F. Käshammer and A. Nüchter, “MIRROR IDENTIFICATION AND CORRECTION OF 3D POINT CLOUDS,” *Int. Arch. Photogramm. Remote Sens. Spat. Inf. Sci.*, vol. XL-5/W4, pp. 109–114, Feb. 2015, doi: 10.5194/isprsarchives-XL-5-W4-109-2015.
- [14] E. Yamaguchi, H. Higuchi, A. Yamashita, and H. Asama, “Glass Detection Using Polarization Camera and LRF for SLAM in Environment with Glass,” in *2020 21st International Conference on Research and Education in Mechatronics (REM)*, Cracow, Poland: IEEE, Dec. 2020, pp. 1–6. doi: 10.1109/REM49740.2020.9313933.
- [15] H. Wei, X. Li, Y. Shi, B. You, and Y. Xu, “Multi-sensor Fusion Glass Detection for Robot Navigation and Mapping,” in *2018 WRC Symposium on Advanced Robotics and Automation (WRC SARA)*, Beijing: IEEE, Aug. 2018, pp. 184–188. doi: 10.1109/WRC-SARA.2018.8584213.
- [16] 青木系展 and 柳澤政生, “RGB-D SLAM における鏡とガラスのマッピング手法,” in *情報処理学会第 81 回全国大会講演論文集*, Mar. 2019, pp. 2-227-2–228.
- [17] U. Klank, D. Carton, and M. Beetz, “Transparent object detection and reconstruction on a mobile platform,” in *2011 IEEE International Conference on Robotics and Automation*, Shanghai, China: IEEE, May 2011, pp. 5971–5978. doi: 10.1109/ICRA.2011.5979793.
- [18] H. Mei *et al.*, “Don’t Hit Me! Glass Detection in Real-World Scenes,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Seattle, WA, USA: IEEE, Jun. 2020, pp. 3684–3693. doi: 10.1109/CVPR42600.2020.00374.
- [19] Y. Zhao, H. Li, S. Jiang, H. Li, Z. Zhang, and H. Zhu, “Glass Detection in Simultaneous Localization and Mapping of Mobile Robot Based on RGB-D Camera,” in *2023 IEEE International Conference on Mechatronics and Automation (ICMA)*, Harbin, Heilongjiang, China: IEEE, Aug. 2023, pp. 549–556. doi: 10.1109/ICMA57826.2023.10216171.
- [20] D. Hutchison *et al.*, “Camera Pose Estimation Using Images of Planar Mirror Reflections,” in *Computer Vision – ECCV 2010*, vol. 6314, K. Daniilidis, P. Maragos, and N. Paragios, Eds., in *Lecture Notes in Computer Science*, vol. 6314, Berlin, Heidelberg: Springer Berlin Heidelberg, 2010, pp. 382–395. doi: 10.1007/978-3-642-

15561-1_28.

- [21] J. Wang and E. Olson, “AprilTag 2: Efficient and robust fiducial detection,” in *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Daejeon, South Korea: IEEE, Oct. 2016, pp. 4193–4198. doi: 10.1109/IROS.2016.7759617.
- [22] Z. Chen, Z. Wang, Q. Gao, M. Mikawa, and M. Fujisawa, “Dense Reconstruction and Localization in Scenes with Glass Surfaces Based on ORB-SLAM2,” in *Pattern Recognition*, vol. 15330, A. Antonacopoulos, S. Chaudhuri, R. Chellappa, C.-L. Liu, S. Bhattacharya, and U. Pal, Eds., in Lecture Notes in Computer Science, vol. 15330., Cham: Springer Nature Switzerland, 2025, pp. 393–410. doi: 10.1007/978-3-031-78113-1_26.
- [23] J. Tan, “Mirror3D: Depth Refinement for Mirror Surfaces”.
- [24] A. Arnolte, Y. Son, and C. Chen, “Final Report: Detection of Mirrors in 3D Scenes from 2D Images”.
- [25] J. Jiang, G. Cao, J. Deng, T.-T. Do, and S. Luo, “Robotic Perception of Transparent Objects: A Review,” Oct. 17, 2023, *arXiv*: arXiv:2304.00157. doi: 10.48550/arXiv.2304.00157.
- [26] K. Tong *et al.*, “Confusing Object Detection: A Survey,” *Comput. Mater. Contin.*, vol. 80, no. 3, pp. 3421–3461, 2024, doi: 10.32604/cmc.2024.055327.
- [27] “ROBOTIS e-Manual,” ROBOTIS e-Manual. Accessed: Dec. 17, 2025. [Online]. Available: <https://manual.robotis.com/docs/en/platform/turtlebot3/locomotion/>
- [28] “RealSense Documentation - Get Started,” RealSense Developer Documentation. Accessed: Dec. 17, 2025. [Online]. Available: <https://dev.realsenseai.com/docs/docs-get-started>
- [29] “christianrauch/apriltag_ros: ROS 2 node for AprilTag detection.” Accessed: Jan. 18, 2026. [Online]. Available: https://github.com/christianrauch/apriltag_ros
- [30] “HarvestX/PlayStation-JoyInterface-ROS2: PlayStation Joy Controller Interface Package for ROS2.” Accessed: Jan. 18, 2026. [Online]. Available: <https://github.com/HarvestX/PlayStation-JoyInterface-ROS2>
- [31] Thingiverse.com, “ROBOTIS TurtleBot Carrier by ROBOTIS,” Thingiverse. Accessed: Jan. 18, 2026. [Online]. Available: <https://www.thingiverse.com/thing:3069815>
- [32] “OAK-D S2,” Luxonis. Accessed: Jan. 19, 2026. [Online]. Available: <https://docs.luxonis.com>
- [33] S. Macenski, T. Foote, B. Gerkey, C. Lalancette, and W. Woodall, “Robot Operating System 2: Design, architecture, and uses in the wild,” *Sci. Robot.*, vol. 7, no. 66, p.

eabm6074, May 2022, doi: 10.1126/scirobotics.abm6074.

- [34]X. Yang, H. Mei, K. Xu, X. Wei, B. Yin, and R. Lau, “Where Is My Mirror?,” in *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Seoul, Korea (South): IEEE, Oct. 2019, pp. 8808–8817. doi: 10.1109/ICCV.2019.00890.
- [35]J. Lin, G. Wang, and R. W. H. Lau, “Progressive Mirror Detection,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Seattle, WA, USA: IEEE, Jun. 2020, pp. 3694–3702. doi: 10.1109/CVPR42600.2020.00375.
- [36]X. Zhao and S. Schwertfeger, “3DRef: 3D Dataset and Benchmark for Reflection Detection in RGB and Lidar Data,” in *2024 International Conference on 3D Vision (3DV)*, Davos, Switzerland: IEEE, Mar. 2024, pp. 225–234. doi: 10.1109/3DV62453.2024.00009.